# 朴素贝叶斯 (预习部分)

此PPT只包含有必要预习的部分

### 朴素贝叶斯 - 核心思想

### 焆江此刀 闸线以上凹复门台###

您提交的#3152号工单:来自于李先生的留言有更新。

请点击以下链接查看工单处理进度:

https://tingyun.kf5.com/hc/request/view/3152/

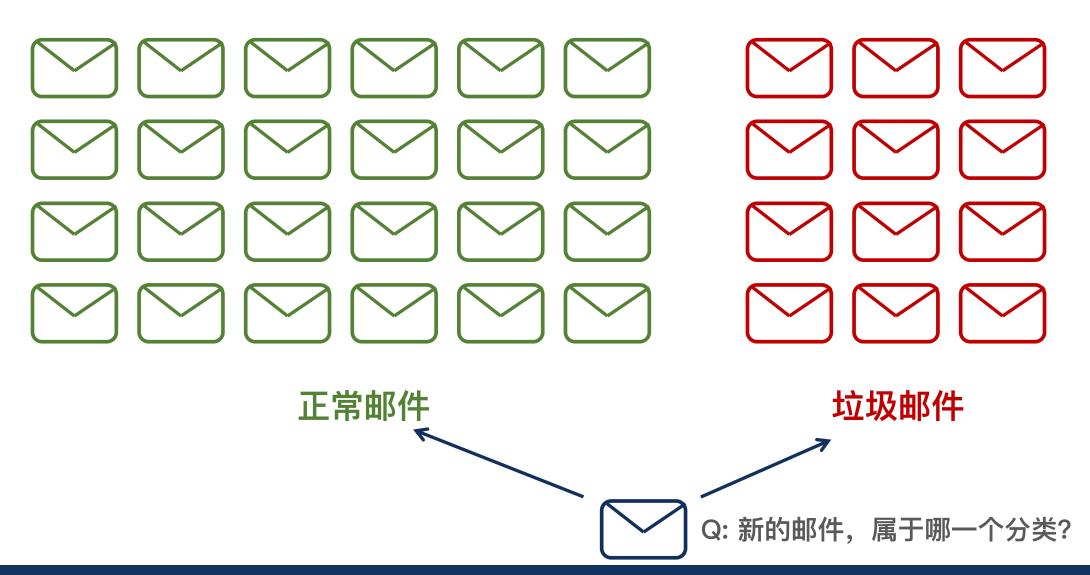
要添加另外的工单评论,请回复此邮件。

在垃圾邮件里经常出现"链接","点击"这种单词。

假如一个邮件里包含了这些单词,这个邮件很可能是垃圾邮件。

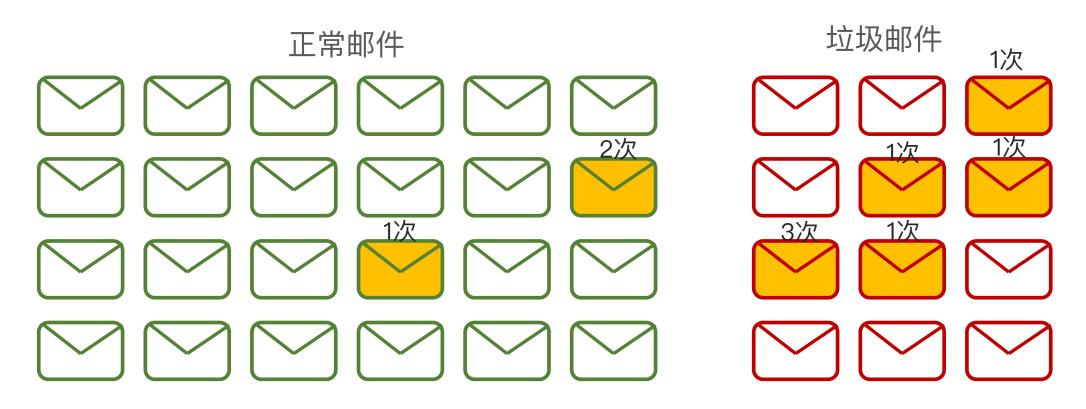
# 一个简单的例子: 垃圾邮件分类

### 垃圾邮件分类



### 对于"购买"单词

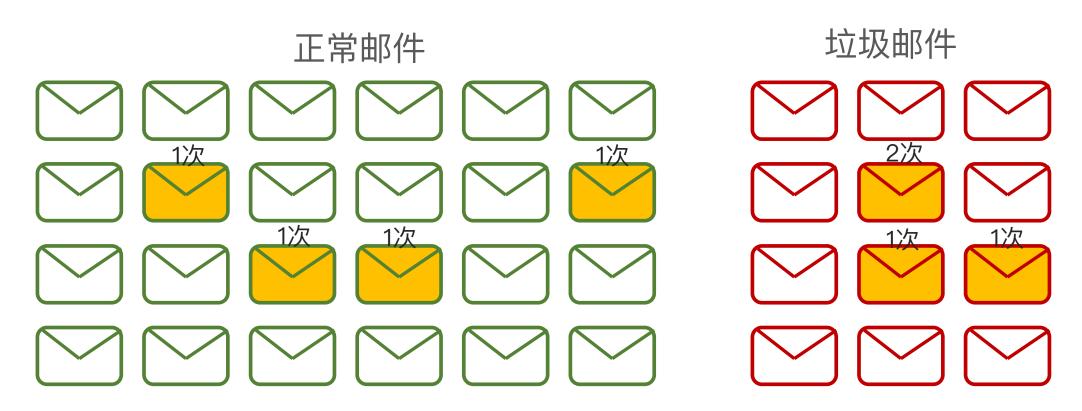
假设:每个邮件包含10个单词



正常邮件含有"购买"词的概率多少? p("购买"|正常) = 3/(24\*10) = 1/80

垃圾邮件含有"购买"词的概率多少? p("购买"|垃圾) = 7/(12\*10) = 7/120

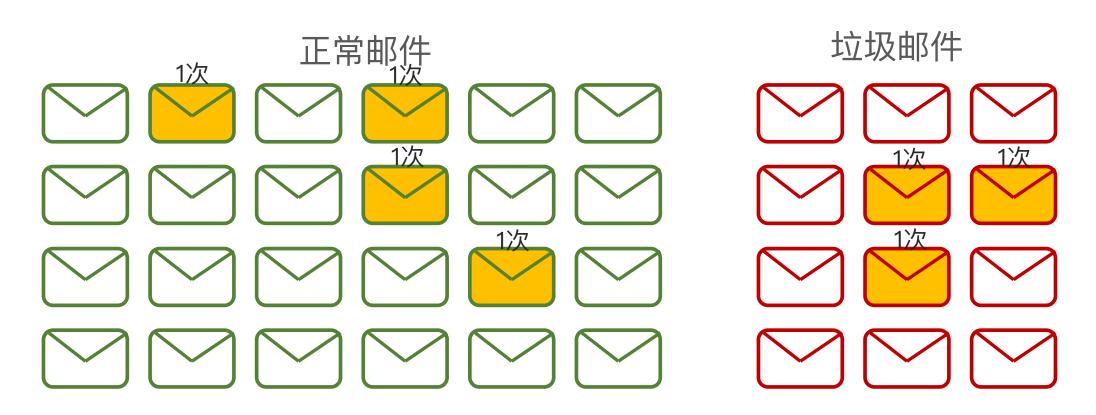
### 对于"物品"单词



正常邮件含有"物品"词的概率多少?

垃圾邮件含有"物品"词的概率多少?

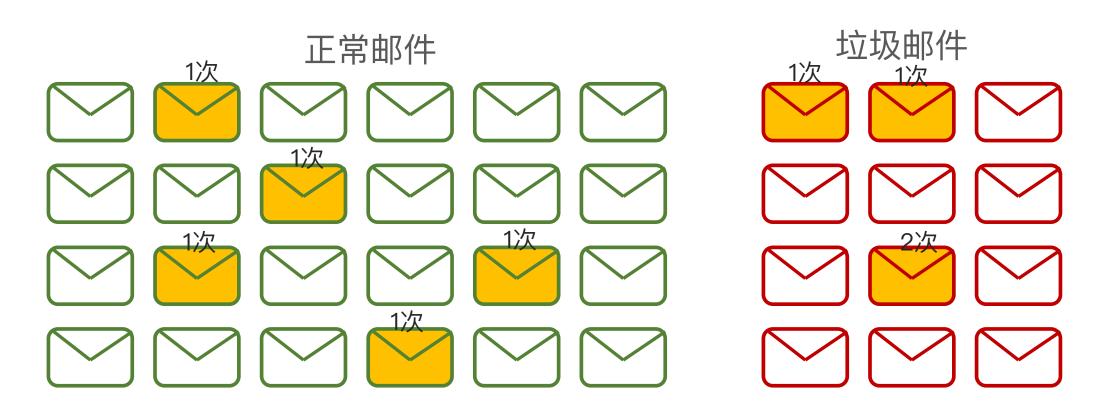
# 对于"不是"单词



正常邮件含有"不是"词的概率多少?

垃圾邮件含有"不是"词的概率多少?

# 对于"广告"单词



正常邮件含有"广告"词的概率多少?

垃圾邮件含有"广告"词的概率多少?

### 还有一个概率需要统计



有多少邮件是正常邮件(百分比)?

有多少邮件是垃圾邮件(百分比)?

### 利用朴素贝叶斯识别垃圾邮件

前面计算出了很多零零散散的概率,怎么整合这些信息来完成识别任务?

#### 从概率统计的角度

P(垃圾|邮件内容): 一个邮件内容为垃圾邮件的概率

P(正常|邮件内容): 一个邮件内容为正常邮件的概率

#### 如何做判断?

如果 P(垃圾|邮件内容) > P(正常|邮件内容), 则可以认为是垃圾邮件 如果 P(垃圾|邮件内容) <= P(正常|邮件内容), 则可以认为是正常邮件

新的问题: P(垃圾|邮件内容), P(正常|邮件内容) 怎么计算???

回顾: 贝叶斯定理



P("购买"|正常) = P("购买"|垃圾)=

P("物品"|正常) = P("物品"|垃圾)=

P("不是"|正常) = P("不是"|垃圾)=

P("广告"|正常) = P("广告"|垃圾)=

P(正常) = P(垃圾) =



#### 是垃圾邮件还是正常邮件?

 $P(正常 \mid \text{邮件内容}) = \frac{P(\text{邮件内容}|\text{正常})*p(正常)}{p(\text{邮件内容})}$ 

 $=\frac{P("购买", "物品", "不是", "广告"|正常)*<math>p$ (正常)}{p(邮件内容)

 $=\frac{P\left(\text{"MX"}\big|\text{ER}\right)*P\left(\text{"The"}\big|\text{ER}\right)*P\left(\text{"The"}\big|\text{ER}\right)}{p(\text{mtho})}$ 

 $P(垃圾 \mid \text{邮件内容}) = \frac{P(\text{邮件内容}|垃圾)*p(垃圾)}{p(\text{邮件内容})}$ 

# 手推一个完整的例子

#### 垃圾邮件

- 1. 点击 获得 更多 信息
- 2. 购买 最新产品获得优惠
- 3. 优惠 信息 点击 链接

#### 正常邮件

- 1. 明天 一起 开会
- 2. 开会 信息 详见 邮件
- 3. 最新 竞品 信息

#### 新邮件

最新 产品 实惠 点击 链接



属于正常邮件还是垃圾邮件?

### 利用严格的数学来表示朴素贝叶斯过程

给定一个文本 $s = (x_1, ..., x_m)$ ,以及两种类型标签  $y = \{0,1\}$ ,我们需要计算

p(y = 0|s) 以及 p(y = 1|s) 。在这里s可以看做是文本向量。